

Examen de Recuperación – Desarrollo y despliegue de un servicio web de Information Retrieval

1. Instrucciones:

En este examen, los estudiantes deberán desarrollar y publicar en Internet un servicio web basado en Generación Aumentada por Recuperación —RAG— que responda preguntas sobre Recuperación de Información utilizando bibliografía.

El servicio web recibirá una pregunta de un examen de Recuperación de Información, en formato Markdown, y devolverá una respuesta que incluya fuentes bibliográficas.

Cada respuesta deberá incluir:

- a. La pregunta identificada.
- b. La respuesta generada.
- c. Las referencias bibliográficas utilizadas.
- d. Los identificadores de los chunks recuperados.
- e. El contenido textual de los chunks empleados como evidencia.
- f. La información necesaria para verificar la procedencia de cada chunk.

El servicio será evaluado mediante Postman. No se requiere desarrollar una interfaz gráfica ni una interfaz de chatbot.

2. Corpus

El corpus deberá incluir obligatoriamente el libro de la asignatura: Baeza-Yates, R. y Ribeiro-Neto, B. Modern Information Retrieval. El contenido del libro deberá extraerse desde el documento PDF, procesarse y dividirse en chunks que serán los documentos del corpus.

Adicionalmente, deberá incluirse como fuente bibliográfica: Manning, C. D., Raghavan, P. y Schütze, H. Introduction to Information Retrieval.

2.1. Bibliografía complementaria

El estudiante deberá ampliar el corpus con bibliografía adicional relacionada con los contenidos de la asignatura.

El corpus deberá contener como mínimo:

- a. Los dos libros obligatorios.
- b. Al menos un libro adicional.
- c. Tres artículos científicos.

Importante: No se permite incorporar al corpus contenido generado por modelos de lenguaje.

3. Procesamiento del corpus

El corpus deberá ser procesado siguiendo al menos estas operaciones:

- a. Lectura y extracción de texto desde documentos PDF.

- b. Limpieza de encabezados, pies de página y contenido repetitivo.
- c. Identificador del documento de origen.
- d. Conservar los números de página.
- e. División del contenido en chunks.
- f. Asignación de identificadores únicos a los chunks.
- g. Generación de embeddings.
- h. Indexación en una base vectorial.

Cada estudiante deberá verificar que la extracción de texto sea legible y que los chunks no contengan errores producidos durante el procesamiento del archivo.

4. Retrieval

Para cada pregunta del examen enviada al servicio web, el sistema deberá realizar una búsqueda independiente en el corpus.

El sistema deberá:

- a. Generar una representación de la pregunta.
- b. Consultar la base vectorial.
- c. Recuperar un conjunto inicial de chunks candidatos.
- d. Conservar el score de recuperación de cada chunk.
- e. Seleccionar un conjunto top-k.
- f. Enviar únicamente evidencia recuperada al proceso de generación de la respuesta.

Asimismo, el sistema deberá implementar una etapa de re-ranking. Para esto, la respuesta del servicio deberá permitir diferenciar el score de recuperación inicial del score de re-ranking.

5. Generación de respuestas

El sistema deberá utilizar un modelo generativo para redactar las respuestas. La generación deberá realizarse exclusivamente a partir de la evidencia recuperada del corpus. El modelo no deberá utilizar conocimientos externos que no puedan verificarse mediante los chunks recuperados.

6. Manejo de información insuficiente

El sistema no deberá inventar respuestas. Cuando no exista evidencia suficiente en el corpus, el sistema deberá indicarlo explícitamente.

7. Servicio web

El sistema deberá exponerse como un servicio web accesible públicamente mediante Internet. No se requiere una interfaz gráfica. El servicio deberá utilizar HTTPS y deberá permanecer disponible durante el periodo de evaluación.

El estudiante deberá entregar:

- a. URL base del servicio.
- b. Endpoint principal.
- c. Método HTTP utilizado.
- d. Formato de la solicitud.
- e. Formato de la respuesta.
- f. Documentación de los endpoints.
- g. Ejemplo de consumo mediante Postman.
- h. Ejemplo de consumo mediante curl.
- i. Códigos de estado utilizados.

8. Referencias bibliográficas

Cada respuesta deberá incluir referencias bibliográficas verificables.

Las referencias deberán indicar:

- a. Identificador del chunk.
- b. Título del documento.
- c. Página o rango de páginas.
- d. Capítulo o sección.
- e. Texto del chunk.
- f. Página o rango de páginas.
- g. Score de recuperación, y score de re-ranking.

9. Documentación de la API

La documentación del servicio web debe incluir:

- a. Descripción general del servicio.
- b. Arquitectura del sistema.
- c. Lista de endpoints.
- d. Métodos HTTP.
- e. Parámetros obligatorios y opcionales.
- f. Ejemplos de solicitudes.
- g. Ejemplos de respuestas.
- h. Códigos de estado.
- i. Posibles mensajes de error.

10. Códigos de estado HTTP

El servicio deberá utilizar apropiadamente los códigos de estado HTTP.

200: solicitud procesada correctamente.

400: solicitud inválida o ausencia del campo *question*.

404: endpoint o recurso no encontrado.

422: la solicitud es válida, pero no fue posible identificar preguntas en el contenido recibido.

500: error interno del servidor.

503: el modelo, la base vectorial o algún componente requerido no se encuentra disponible.

11. Despliegue

El servicio podrá desplegarse en cualquier plataforma que permita acceso público mediante Internet.

12. Formato de Entrega

- **Jupyter Notebook**

El notebook debe incluir el código y la documentación de todo el proceso de desarrollo del sistema.

- **Documentación**

En el Notebook se deberá presentar el link a la URL donde se tenga desplegado el sistema.